

봉강 불꽃 영상 기반의 강종 혼재
감별 기술 기초 연구

Basic Research on Steel Type Distinction Technology
Based on Spark Video

School of Mechanical and Control Engineering
Handong Global University

Eun-Chan Kim

봉강 불꽃 영상 기반의 강종 혼재

감별 기술 기초 연구

Basic Research on Steel Type Distinction Technology
Based on Spark Video

A Bachelor's Thesis

Submitted to the School of
Mechanical and Control Engineering of
Handong Global University

Eun-Chan Kim

December 2023

This certifies that the bachelor's thesis is approved.



Thesis Advisor: Ph.D. Young-Keun Kim

The Dean of Faculty: Ph.D. Chong-Sun Lee

School of Mechanical and Control Engineering

Handong Global University

December 2023

Extended Abstract

Basic Research on Steel Type Distinction Technology Based on Spark Video

In this research, the differentiation of steel type by analyzing the spark patterns corresponding to carbon content through image processing is investigated, aiming to enhance the technology for discerning mixed steel type. Steel rods are produced in a continuous process where different types of steel are manufactured on the same line. Occasionally, this leads to incidents of steel grade mixing, which can escalate to full product recalls, incurring significant economic losses. Thus, there is a pressing need for technology capable of distinguishing mixed steel type. To prevent such incidents, equipment for discerning mixed steel type is currently in use on-site.

However, although this equipment performs well in discriminating between different metals, it struggles with the differentiation of steel type based on carbon content. The visual similarities between different steel grades make it challenging to prevent mixing. Moreover, despite the equipment's high cost, exceeding 100 million won per unit, there remain areas for improvement.

This research aims to develop a method for distinguishing steel grades based on carbon content. A common method for identifying steel grades is the spark test, which involves observing the shape of sparks produced during grinding. It is known that the spark patterns of steel vary with carbon content[1]. The spark test is recognized as a simple and inexpensive method for steel grade identification. As the carbon content in steel increases, the number of explosive branches and the brightness of the sparks also increase, while the length of the sparks decreases.

By applying image processing techniques to these spark characteristics, it is anticipated that a technology for discerning steel grade mixtures could be developed. Efforts to classify steel type using the spark test have been underway for some time. However, previous studies did not utilize the spark characteristics associated with carbon content and only conducted steel grade differentiation for carbon content differences exceeding 0.1%. Moreover, these studies were based on images, making it difficult to verify the feasibility of real-time implementation.

Therefore, this study utilized known spark test methods to differentiate steel types based on spark characteristics corresponding to carbon content, including differences within 0.1%. For the classification of steel grades, data was preprocessed using image processing techniques, and features reflecting spark characteristics based on carbon content were extracted and applied to machine learning

to create a classification model.

Image processing techniques that exploit the increasing number of explosive spark branches were advantageous for feature extraction. The dataset underwent two preprocessing steps to reflect the number of spark branches according to carbon content. Initially, PCA was used to detect only the exploding spark points. However, overlapping stem sparks were mistakenly identified as exploding sparks. As a second method, stem sparks that did not reflect the characteristics of the steel grades were removed. The spark images were frequency-transformed using FFT, and components corresponding to stem sparks were eliminated. This allowed for the isolation of only the exploding sparks through inverse transformation using IFFT. Statistical features were then extracted from these preprocessed images, and the SFS technique was used to select the best features reflecting the characteristics of the steel type. These features were applied to machine learning to create a classification model that conducted steel type differentiation.

The model performance evaluation showed that steel with 0.53% and 0.55% carbon content exhibited the best classification performance, confirming that classification is possible even within 0.1% differences in steel grades. However, for 0.2% and 0.4% carbon steels, the model struggled to predict classes properly, a problem attributed to the significantly smaller size of the training dataset for these classes compared to others.

This research proposed a spark pattern-based technology for discerning steel type mixtures, capable of classifying carbon steels with less than 0.1% variance and applicable in real-time. Nonetheless, given the need for performance improvements, acquiring additional data to enhance accuracy is necessary.

차 례

Extended Abstract	i
I. 서론	5
1.1. 연구 필요성	5
1.1.1. 연구 배경	5
1.1.2. 기존 검사 장비	5
1.1.3. 선행 연구	5
1.2. 연구목표	7
II. 연구방법	8
2.1. 알고리즘 개요 및 데이터 소개	8
2.2. 데이터 전처리	9
2.1.1. 스파크 영역 추출	9
2.1.2. 줄기 스파크 제거	14
2.3. 특징 추출	18
2.2.1. SFS 이용	18
2.4. 머신러닝 분류	19
2.3.1. SVM	19
2.3.2. KNN	20
2.3.3. Random Forest	21

III. 결과	22
IV. 결론 및 추가연구	24
참고문헌	25
부록	25

I. 서론

1.1. 연구 필요성

1.1.1. 연구배경

강봉은 연속 공정으로 구성되어 있기에 서로 다른 강재가 한 라인에서 생산되게 된다. 때문에 간혹 강종이 섞이는 혼재 사고가 발생하게 되고 전량 리콜 사태로 이어지곤 한다. 이는 막대한 경제적 손실을 유발하기에 강종 혼재를 예방할 시스템이 필요로 하다.

1.1.2. 기존 검사 장비

강종 혼재로 인한 제품 품질 저하를 방지하기 위해 현장에서는 강종 혼재 감별 장비가 사용되고 있다. 해당 장비는 대당 1 억원이 넘는 금액으로 고가의 가격대를 형성하고 있음에도 여전히 개선점이 남아 있다. 강종 혼재 감별 장비는 서로 다른 금속에 대해서는 좋은 감별 성능을 보이지만 탄소 함유량에 따른 강종 간 구분은 쉽지 않은 상황이다. 서로 다른 강종은 육안으로도 보이는 차이점이 크게 없어 강종 혼재를 막기 어렵다. 때문에 높은 신뢰성을 보이는 강종 혼재 감별 기술이 필요로 한 상황이다. 이번 연구에서는 영상처리 기반의 탄소 함유량에 따른 강종 혼재 감별 기법을 개발하여 강종 혼재 사고를 막을 수 있는 기법을 고안하고자 한다.

1.1.3. 선행 연구

강종을 구분할 수 있는 방법에는 대표적으로 연삭 시 발생하는 스파크의 모양을 보고 구분하는 스파크 테스트다. 강철은 탄소 함유량에 따라 스파크의 형태가 다르다고 알려져 있다[1]. 스파크 테스트는 이를 활용한 강종 구분 방법으로 간단하고 저렴한 방법으로 알려져 있다. 강철 연삭 시 탄소 함유량이 높을수록 떨어져 나오는 스파크의 탄소 입자가 크다. 연삭 시 큰 입자를 떼어내는데 더 큰 에너지가 필요함으로, 그림 1 과 같이 강철은 탄소 함유량이 증가할수록 폭발하는 가지의 개수가 많아지고 밝기가 증가하며, 스파크 길이가 짧아진다. 이러한 스파크 특성을 이용해 숙련된 작업자는 육안으로 강종 구분이 가능하다. 하지만 사람에 따라 정확도가 다르고 신뢰성 측면에서

안정성이 떨어지기 때문에 스파크 테스트에 영상처리 기법을 활용하여 강종을 구분하는 연구가 진행되었다.




그림 1. 탄소 함유량에 따른 강철 스파크 형태

Takeo Nakata 는 스파크 줄기와 폭발하는 지점 개수를 이용하여 폭발 스파크 수의 비율로 강종을 구분하였고[2], Kexing Dengdhl 등은 스파크 이미지를 Box Counting 기법을 사용하여 프렉탈 차원 값을 특징으로 구분하였다[3]. 이 기법은 이미지의 표면 품질을 평가하는데 주로 사용되며 이를 특징으로 사용한 것이다. Pedro José Pacheco Kerscher 등은 스파크의 컨투어를 탐지하여 컨투어 면적을 특징으로 강종을 구분하였다[4].

이 연구들은 모두 알려진 탄소 함유량에 따른 스파크 특성을 특징으로 택한 것이 아닌 이미지의 질감, 복잡도 등을 특징으로 사용하였다. 또한 0.1% 이상의 탄소 함유량 격차의 좁은 범위의 강종에 대해서만 구분을 실시했다. 한 프레임의 이미지를 기반으로 연구가 진행되어 실시간 구현 가능성을 확인하기 어렵다는 단점이 있다.

때문에 이번 연구에서는 알려진 스파크 테스트 기법을 활용하여 탄소 함유량에 따른 스파크 특성을 특징으로 강재 구분을 진행할 것이고, 0.1% 이내 격차에 대해서도 강재 구분을 진행할 것이다.

1.2. 연구목표

연구 목표는 스파크 영상 기반의 강종 혼재 감별 기술을 개발하는 것이다. 스파크 테스트를 활용하여 탄소 함유량에 따른 스파크 모양 차이를 기반으로 영상처리 기법을 사용하여 강종 혼재 감별 기술을 개발하도록 한다. 또한 탄소 함유량 0.1% 이내의 격차의 강종 간 분류를 진행할 것이며 실시간 적용이 가능하도록 연구를 진행하도록 하여 선행 연구에서 더 나아가고자 한다.

본 연구는 강종 혼재 감별 기술을 개발하여 혼재 사고를 예방하는데 그 목적이 있다.

II. 연구 방법

2.1. 알고리즘 개요 및 데이터 소개

스파크 영상을 사용한 강종 구분 영상처리 기법의 흐름은 그림 1.2와 같다. 먼저 필요로 하는 객체만 집중하기 위해 스파크 영상에서 스파크와 배경을 분리 한다. 이후 탄소 함유량에 따른 스파크 특성을 잘 반영하는 특징을 추출하고 이를 SVM(Support Vector Machine), KNN(K-Nearest Neighbor), Random Forest에 적용하여 분류 모델을 제작한다. 결과적으로 만들어진 분류 모델을 통해 스파크 영상을 이용해 강종 분류를 진행한다.

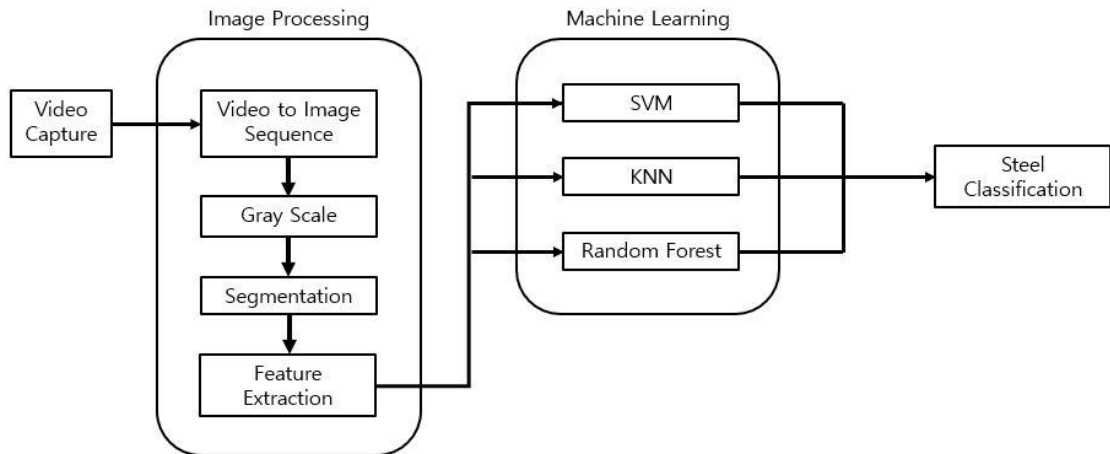


그림 2.1. 강종 분류를 위한 흐름도

사용할 스파크 데이터는 강봉을 연삭기에 수직으로 힘을 가해 수집되었다. 검은색 배경에서 스파크 영상이 촬영되어 스파크가 배경과 구분되도록 제작 되었으며 44FPS 및 3074x2048 해상도로 촬영되었다. 강종은 0.1%, 0.2%, 0.25%, 0.35%, 0.4%, 0.53%, 0.55% 탄소강으로 총 7 가지의 강종으로 구성되어 있다.

2.2. 데이터 전처리

그림 1에서 확인했듯이 탄소 함유량이 증가할수록 강종의 스파크는 더 많은 폭발까지 개수를 가진다. 이에 따른 스파크 특성을 데이터로 활용하기 위해서는 폭발하는 스파크 외의 정보를 지우는 데이터 전처리가 중요하다. 이를 위해 본 연구에서는 스파크 영역 추출과 줄기 스파크 제거 두 가지 방법을 진행하였다.

2.2.1. 스파크 영역 추출

정확한 폭발 스파크 영역만 데이터로 활용하여 탄소 함유량에 따른 스파크 특성을 잘 반영하고자 한다. 스파크 영역을 추출하는 것은 상대적으로 가벼운 알고리즘으로 폭발하는 지점만 데이터로 확보하는 것을 가능케한다. 이를 위해 그림 2.2와 같은 과정을 거쳤다.

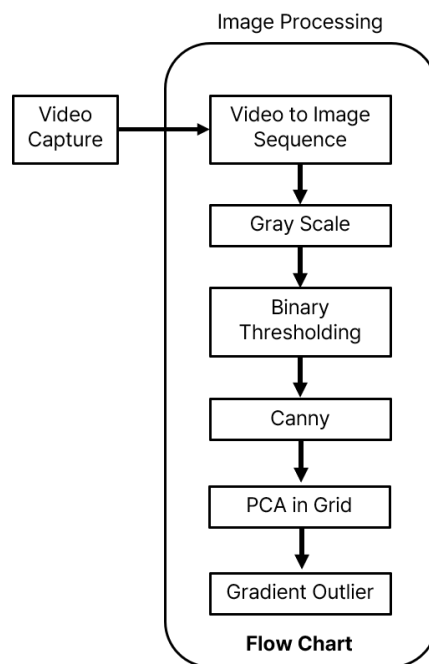


그림 2.2. 폭발 스파크 영역 추출 과정

원본 영상을 보게 되면 그림 2.2(a)와 같이 검은 바탕에서 스파크가 생성되어 구분하기 용이하도록 촬영되었다. 불필요한 구조물과 스파크들이 겹쳐 스파크 특성을 파악하기 힘든 영역을 제거하기 위해 ROI를 설정하였다. X 좌표는 0에서 1700까지로 설정하였고


Y 좌표는 700 에서 2743 까지 설정하였다. 설정된 ROI 를 그레이 스케일로 변환하고 이진화를 진행하여 스파크 외의 모든 값들을 0 으로 변환하였다.



(a)원본 스파크 영상



(b)ROI 설정 결과



(c)그레이 스케일 변환



(d)이진화 결과

그림 2.3. 스파크 이미지 전처리

이진화 처리를 통해 이미지는 스파크 데이터만 남게 되었다. 폭발하는 스파크 영역이 강중 특성을 잘 반영하므로 해당 영역만 추출하는 것이 필요로 하다. 이를 위해 주성분분석(Principal Component Analysis, 이하 PCA)를 사용하여 폭발 영역을 탐지하고자 한다. PCA는 차원 축소 방법 중 하나로 흩어져 있는 데이터들의 차원을 축소함으로써 주요한 성분 즉, 데이터의를 가장 잘 반영하는 방향을 측정할 수 있다. 폭발하는

스파크는 줄기 스파크와 달리 방향성이 급격하게 변화한다. 따라서 PCA 를 사용하게 되면 폭발하는 스파크의 방향성을 측정할 수 있고, 이를 기반으로 어느 지점에 폭발 스파크가 위치하는지 탐지할 수 있다.

이를 위해 먼저 Canny 기법을 통해 이미지에서 가장자리를 탐지하도록 하였다. 이후 ROI 를 15x15 픽셀 단위로 쪼개어 각 영역의 PCA 를 측정하고 기울기를 측정하였다. 모든 영역의 PCA 기울기 값을 가지고 Z score 를 측정하여 스파크의 전반적인 흐름과 차이가 나는 이상 값을 탐지했다. Z score 이상 값들은 폭발하는 스파크 영역에서 PCA 기울기가 크게 달라지므로 발생한 값들이다. Z score 이상 값이 위치한 영역을 시각화 하면 그림 2.3 과 같은 결과가 나온다. PCA 이상 값들이 위치한 영역의 기울기를 빨간색으로 표시하였다.




그림 2.4. PCA 기울기 기반 폭발 영역 탐지

위 그림에서 확인 할 수 있듯이 줄기 스파크와 달리 방향성이 급격하게 바뀌는 폭발 지점을 PCA 기울기를 기반으로 탐지할 수 있었다. 이후 밀도 기반 클러스터링(Density Based Spatial Clustering of Applications with Noise, 이하 DBSCAN)을 활용하여 기울기 이상 값 영역을 군집화 하였고 군집의 중심 기준 상하좌우 150 픽셀 씩 확장하여 그림 2.5 와 같이 폭발 스파크 영역을 탐지할 수 있었다.




그림 2.5. 폭발 스파크 영역 탐지

아래 그림 2.6 과 같이 폭발하는 스파크 영역을 탐지하는 것이 가능케 됐다. 하지만 폭발 스파크 외에, 줄기 스파크가 겹쳐짐으로 인해 이를 폭발 스파크로 인지하고 탐지 되는 것을 확인하였다. 줄기 스파크는 탄소 함유량에 따른 스파크 특성을 잘 반영하지 못하므로 이를 데이터로 활용할 시 특성 반영이 어려울 수 있다. 따라서 스파크 영역 탐지 방법 외에 줄기 스파크 자체를 제거하는 방안을 고려하였다.




그림 2.6. ROI 내 폭발 스파크 영역 탐지 결과

2.2.2. 줄기 스파크 제거

줄기 스파크 자체를 제거하게 되면 폭발하는 스파크 값만 남길 수 있으므로, 탄소 함유량에 따른 스파크 특성을 더 잘 반영할 수 있다. 폭발하는 스파크 영역은 다른 영역과 달리 급변하는 데이터들이 존재한다. 이를 활용해 이미지를 주파수 변환한다면 고주파 영역에서 폭발하는 스파크 데이터들이 많이 분포되어 있을 것으로 판단했다.

Kruk, Adam 등은 원본 이미지에 2D FFT를 적용하여 이미지 내의 특정 패턴과 매칭되는 FFT 값을 제거함으로써 이미지에서 반복되는 값들을 제거하였다[5]. 이와 동일한 방법으로 스파크 이미지를 FFT 한다면 반복되는 줄기 스파크와 폭발하는 스파크는 서로 다른 FFT 값을 가질 것이다. 따라서 FFT 값에서 반복되는 줄기 스파크 값을 제거하고 역 변환 시킨다면 이미지에서 줄기 스파크를 제거할 수 있다고 판단하였다. 줄기 스파크 제거 알고리즘은 그림 2.7 과 같은 흐름으로 진행되었다.

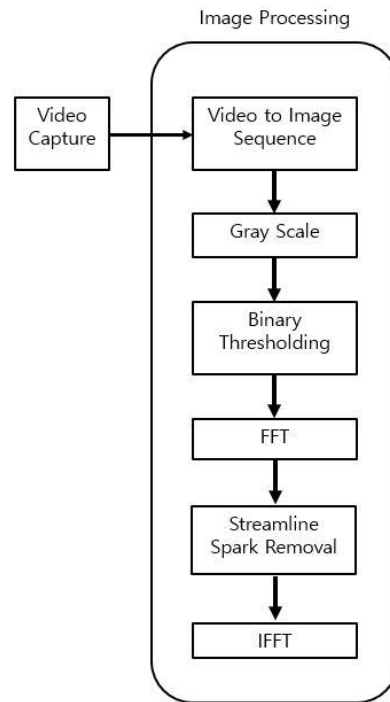
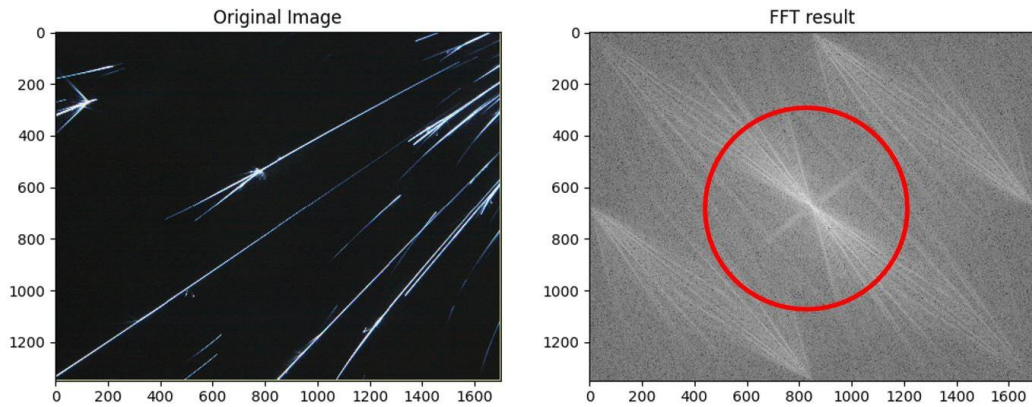



그림 2.7. 줄기 스파크 제거 흐름도

2.2.1의 방법과 동일하게 스파크 이미지를 이진화 하였고 이를 FFT 하여 시각화 하였다. 폭발하는 스파크가 FFT 에서 어떤 양상으로 나타나는지 확인하기 위해 원본 스파크에서 폭발하는 가치를 수작업으로 제거했다. 그 결과 그림 2.7에서 확인할 수

있듯이 폭발하는 가지는 양수 값의 기울기로 나타나는 것을 확인 할 수 있었다. 따라서 반복되는 음의 기울기 패턴을 제거하고 반대 성분만 남긴다면 줄기 스파크를 제거할 수 있을 것이라 판단하였다.



(a) 원본 스파크의 FFT 결과



(b) 폭발 스파크 가지를 제거한 FFT 결과

그림 2.7. 폭발 가지 제거 유무에 따른 스파크 이미지 FFT 결과




그림 2.8. 스파크 이미지 FFT의 Magnitude 그래프

그림 2.8과 같이 스파크 이미지의 FFT 결과에서 Z 축을 Magnitude로 하게 되면 중심부인 저주파 영역에서 값이 큰 것을 확인할 수 있다. 반복되는 패턴은 저주파 영역에 속하므로 Magnitude 값에서 10,000를 임계 값으로 하여 그 이상의 값을 제거하였다. 또한 줄기 스파크 FFT 값과 반대 성분인 폭발 스파크 성분을 유지하기 위해 그림 2.9과 같이 타원 형태로 복원하였다.




그림 2.9. 스파크 FFT 이미지의 마스크 처리

마스킹 처리된 FFT 이미지를 역 변환하여 확인하였다. 그 결과 그림 2.10 (a)와 (b)의 비교를 통해 알 수 있듯이, 줄기 스파크 데이터를 대부분 제거하였고 폭발하는 스파크 영역의 데이터만 남길 수 있었다.



(a) 원본 스파크



(b) 마스킹 후 역 변환한 스파크

그림 2.10. 역 변환 결과

위와 같은 과정을 거쳐 스파크 영상에서 탄소 함유량에 따른 스파크 특성을 잘 나타내는 폭발 스파크 영역만 확보할 수 있었다. 이후 보유한 모든 스파크 영상에 대해 동일한 데이터 전처리를 거쳤고 컨투어 기법을 활용하여 특정 면적 이상의 컨투어를 스파크로 인지하고 영상 프레임 내 각각의 스파크를 데이터로 확보하였다.

2.3. 특징 추출

전처리 된 데이터 셋에서 통계적 특징을 추출하여 학습에 사용하였다. 스파크의 빠른 속도로 인해 영상이 촬영될 때 폭발 정도가 프레임마다 상이하므로 50 개의 스파크의 특징을 평균 계산하여 하나의 데이터로 사용하였다. 스파크 이미지의 에너지, 표준편차, 침도, 왜도 등 통계적 특징 51 개를 추출하였고 특징간 정규화 작업을 진행해 데이터를 스케일링 하였다.

머신러닝을 통해 강종 분류 성능을 높이기 위해서는 탄소 함유량에 따른 스파크 특성을 잘 반영하는 통계적 특징을 모델에 적용해야 한다. 따라서 SFS(Sequential Feature Selection)를 통한 특징 선별 작업을 진행하였다.

2.3.1. SFS 이용

SFS 는 여러 특징들 가운데 학습할 클래스의 특성을 잘 반영하는 상위 특징을 선별하는 기법이다. 모든 특징은 Linear Regression 모델의 예측 성능으로 평가 되어 스파크 특성을 잘 반영하지 못하는 불필요한 특징을 제거하였다. 결과적으로 상위 특징 30 개가 특징으로 선별되었다.

최상위 특징으로 스파크 이미지의 표준편차 값이 선정이 되었다. 강철의 스파크는 탄소 함유량이 커질수록 폭발 스파크 가지 개수가 많아진다. 따라서 이미지에서 스파크 가 더 넓게 분포하게 되고 이는 영역 내의 분산이 커짐과 동일한 의미를 가진다. 표준편차는 데이터의 분산 정도를 나타내는 값이므로 이러한 폭발 스파크 특성에 따른 강종 간 표준 편차 값이 차이가 나는 것을 확인할 수 있다. 탄소 함유량이 커질수록 폭발 가지 개수가 많아지기에 그림 2.11에서 볼 수 있듯이 탄소 함유량이 큰 스파크 이미지의 표준 편차 값이 큰 것이 관측된다.

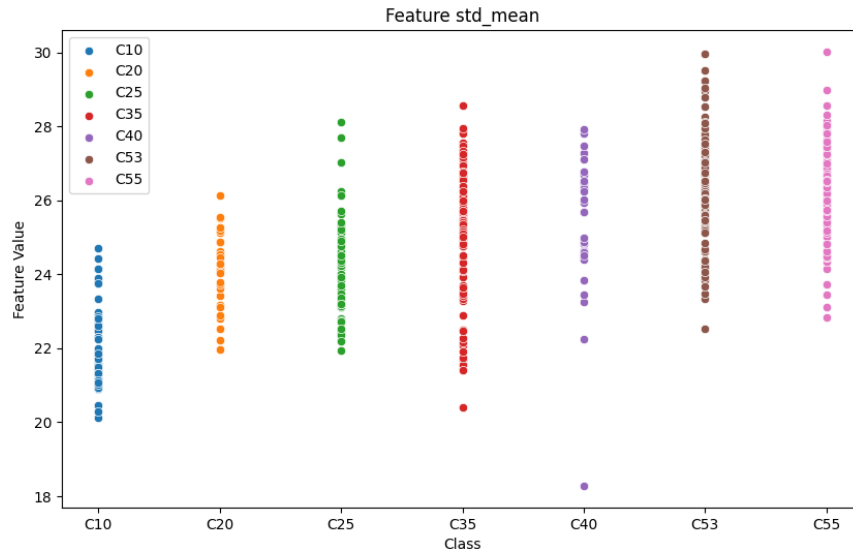


그림 2.11. 스파크 특성 반영 최상위 특징인 표준편차 값

탄소 함유량이 커짐에 따라 특징 값이 커지는 변화하는 경향성을 확인할 수 있지만 분류하기엔 시각적으로 확인이 어렵다. 따라서 이를 머신러닝에 적용하여 통계적 특징을 기반으로 한 강종 분류 모델을 만들고자 한다.

2.4. 머신러닝 분류

선별된 30 가지 특징 값들은 탄소 함유량에 따른 강철 스파크 특성을 잘 반영하는 값들이다. 따라서 이에 머신러닝 분류 모델을 활용하여 특징 값을 기반으로 한 강종 분류 모델을 제작하였다. 학습과 시험 데이터셋은 약 9:1 으로 설정하였고 강종 마다 학습 데이터셋은 약 2,000 개 시험 데이터셋은 약 280 개로 구성되었다. 사용한 모델은 SVM(Support Vector Machine), KNN(K-Nearest Neighbor), Random Forest 기법 세가지이다.

2.4.1. SVM

SVM 은 여러 클래스를 나누는 최적의 결정 경계를 찾는 분류 모델이다. 클래스 사이의 마진을 최대화 하는 결정 경계(Support Vector)를 찾고 마진을 최대화 함으로써 모델의 성능을 향상시킨다. 결정 경계를 기준으로 각 데이터가 어떤 클래스에 속해 있는지 판단하게 된다.

본 연구에서는 선형 커널과 0.5 의 정규화 매개변수를 사용하였다.




그림 2.12. SVM 알고리즘

2.4.2. KNN

KNN 은 새로운 데이터 포인트의 클래스를 예측할 때 가장 가까운 K 개의 이웃 데이터 포인트를 참조한다. K 개의 이웃 중 가장 많은 클래스를 새 데이터의 클래스로 예측함으로써 데이터간 클래스 분류를 수행한다.

본 연구에서는 3 개의 이웃 수를 사용했을 때 가장 좋은 성능을 보였다.




그림 2.13. KNN 알고리즘

2.4.3. Random Forest

Random Forest 분류기는 여러 개의 결정 트리를 훈련시키고 그 결과를 종합하여 작동된다. 각 트리의 예측 중 가장 많이 나온 클래스를 최종 예측 결과로 선정하여 분류를 진행한다.

본 연구에서는 200 개의 결정 나무와 엔트로피로 각 노드의 품질을 측정했다.




그림 2.14. Random Forest 알고리즘

III. 결과

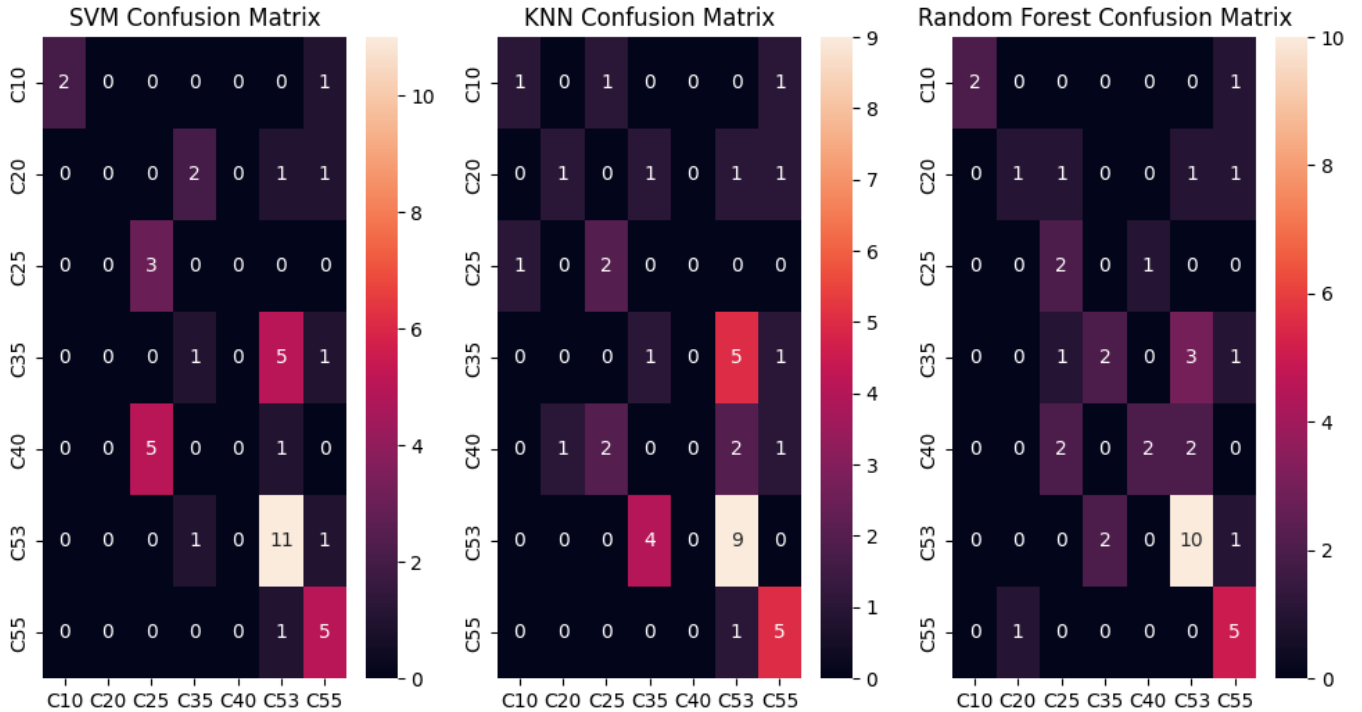


그림 3.1. 가지 모델의 분류 결과 혼동행렬

세가지 분류 모델을 적용하여 강종 간 데이터를 분류한 결과 그림 3.1 과 같은 결과를 보였다. 혼동행렬은 분류 모델의 성능을 시각적으로 파악할 수 있는 방식이다. 이를 통해 실제 클래스와 모델이 예측한 값의 관계를 나타낼 수 있다. X 축은 모델이 예측한 클래스이며 Y 축은 실제 데이터의 클래스이다. 따라서 실제 True 를 True 로, 실제 False 를 False 로 분류 하고 있을 때 왼쪽에서 오른쪽으로 향하는 대각선 위치에 데이터 분포가 많아 지고 모델의 정확도가 높다고 할 수 있다.

표 1. 모델 분류 결과

	SVM[%]	KNN[%]	Random Forest[%]
Accuracy	52.38	45.24	57.14
Precision	63.59	51.67	59.42
Recall	53.38	45.23	57.14

표 1 에서 알 수 있듯이 Random Forest 의 성능이 가장 좋은 것을 확인 할 수 있다. Random Forest 는 여러 개의 결정 트리를 훈련시키고 결과를 집계하는 앙상블 학습 방법을 사용한다. 때문에 각 트리의 오차를 상쇄시키고 전반적인 학습 성능을 향상시킨다. 때문에 SVM 과 KNN 보다 Random Forest 의 성능이 가장 우수하게 나온 것으로 추측된다.

다만 최대 정확도가 57.14% 인 것을 감안하면 이번 연구에서 만들어진 모델을 적용하기엔 정확도가 낮다. 학습에 사용한 데이터 셋을 확인 해보면 표 2 와 같이 0.53, 0.55% 탄소강의 학습 데이터는 3,000 개 이상이고 나머지는 2,000 안팎의 데이터로 구성된다. 표 3 에서와 같이 C20 과 C40 의 성능이 가장 낮은 것을 확인 할 수 있는데 이들의 학습 데이터 셋은 1,000 개 미만으로 가장 적은 수를 보인다. 반면에 Recall 에서 80% 이상을 보인 C53 과 C55 강종은 3,000 개가 넘는 학습 데이터셋을 확인할 수 있다.

이를 통해 알 수 있듯이 데이터셋의 수가 많을수록 분류 정확도가 향상되는 것을 확인할 수 있다. 데이터 셋의 수가 적을수록 학습 시 클래스 특징을 잘 탐지하지 못해 분류 성능이 낮게 된다. 따라서 더 많은 스파크 데이터셋을 확보 한다면 분류 정확도는 높일 수 있을 것으로 판단된다.

표 2. 학습과 시험 데이터 셋의 개수

	C10	C20	C25	C35	C40	C53	C55
Train	1,543	914	1,804	2,764	994	3,964	3,388
Test	120	180	114	341	293	620	289

표 3. 강종 및 모델 별 성능 결과

Steel	Precision[%]			Recall[%]			F1 score[%]		
	SVM	KNN	Random Forest	SVM	KNN	Random Forest	SVM	KNN	Random Forest
C10 (0.1%C)	100	50	100	66.67	33.33	66.67	80	40	80
C20 (0.2%C)	0	50	50	0	25	25	0	33.33	33.33
C25 (0.25%C)	37.5	40	33.33	100	66.67	66.67	54.55	50	44.44
C35 (0.35%C)	25	16.67	50	14.29	14.29	28.57	18.18	15.38	36.36
C40 (0.4%C)	0	0	50	0	0	16.67	0	0	25
C53 (0.53%C)	57.89	50	60	84.62	69.23	69.23	68.75	58.06	64.29
C55 (0.55%C)	55.56	55.56	45.45	83.33	83.33	83.33	66.67	66.67	58.82

IV. 결론 및 추가 연구

강봉 생산 공정은 연속 공정으로 진행되기에 간혹 강재가 섞이는 문제가 발생하곤 한다. 이는 제품의 품질에 치명적으로 작용되어 대량 리콜을 유발하는 막대한 경제적 손실 요소이다. 이를 예방하기 위한 강종 혼재 감별 장비는 1 억원 이상의 고가 장비임에도 불구하고 탄소 함유량에 따른 강종 구분의 개선점이 필요한 현실이다. 따라서 본 연구에서는 스파크 영상 기반의 강종 혼재 감별 영상처리 기술을 개발함으로써 강종 혼재 사고를 막고자 하였다.

연구에서는 스파크 영상을 FFT 로 주파수 변환하고 줄기 스파크 성분을 제거한 뒤 역 변환하여 전처리 하였다. 전처리 된 스파크 영상에서 탄소 함유량에 따른 강종 스파크 특성을 잘 반영하는 특징을 추출하였다. 추출된 특징 값을 SVM, KNN, Random Forest 분류 모델에 적용하여 강종을 구분하였다.

분류 결과 Random Forest 를 사용한 분류 모델이 가장 좋은 성능을 보였으나 정확도가 다소 떨어지는 것을 확인했다. 이는 데이터 셋의 부족으로 발생한 결과이며 데이터 셋을 추가로 수집한다면 분류 성능을 증가시킬 수 있을 것으로 판단된다.

본 연구에서는 선행 연구와 달리 탄소 함유량에 따른 스파크 특성을 이용하는 스파크 테스트를 기반으로 강종 분류를 진행하였다. 환경이 바뀌면 결과가 달라질 수 있는 이미지 특성 기반의 분류가 아닌 모든 환경에서 동일하게 발생하는 강철 특성을 활용하였기에 신뢰성 측면에서 우수하다고 할 수 있다.

데이터 셋이 가장 많은 0.53, 0.55%의 탄소강에서 분류 정확도가 가장 높은 것을 확인할 수 있었고 이를 통해 0.1% 이내의 탄소강에서도 스파크 형태를 특성으로 하여 강종 구분이 가능함을 확인했다. 또한 스파크 50 개에 대해 특징 값 평균을 사용하였으므로 이미지 하나에 대한 분류 모델이 아닌 수 프레임 단위의 분류 모델을 제작하였다. 따라서 만들어진 분류 모델은 이미지 뿐 아니라 실시간 영상 기반에서도 적용이 가능할 것으로 판단된다.

다만 확보한 데이터셋의 수가 적어 분류 성능이 떨어졌기에 데이터 셋을 추가로 확보하여 학습 시킨다면 더 좋은 분류 성능을 낼 수 있을 것으로 기대된다.

참고문헌

- [1] R.W. Buzzard, The utility of the spark test as applied to commercial steels, *U.S. Department of Commerce Bureau of Standards Research Paper*. No.RP-605 Part of Bureau of Standards, J. Res. 11. 527–540. 1933
- [2] Takeo Nakata, Development of Automated Spark Testing Technique by Imaging Processing to Measure Carbon Content in Steel Materials, *IFAC*, Vol.45, No.23, pp. 118~119, 2012
- [3] Kexing Deng, Deng Pan, Xiaobo Li, Fucheng Yin, Spark testing to measure carbon content in carbon steels based on fractal box counting, *Measurement*, Vol.133, pp. 77~80, 2019
- [4] Pedro José Pacheco Kerscher, Jean Schmith, Eduardo Augusto Martins, Rodrigo Marques de Figueiredo, Armando Leopoldo Keller, Steel type determination by spark test image processing with machine learning, *Measurement*, Vol.187, 2022
- [5] Kruk, Adam & Dubiel, B. & Czyrska-Filemonowicz, A.. The 3D imaging and metrology of CMSX-4 superalloy microstructure using FIB-SEM tomography method. *Solid State Phenomena*. Vol.197, 89-94, 2013

Appendix

감사의 글

가장 먼저 기전융합종합설계를 성공적으로 마무리하게 도와 주신 김영근 교수님께 감사 말씀을 드립니다. 처음 하는 연구였기에 부족한 점이 많았는데 세밀히 지도해주시고 연구 진행 방향을 잘 인도해 주셔서 마무리 할 수 있었습니다. 그리고 미팅 때 함께 아이디어 고민해주신 산업 지능화 연구실 석박 분들에게도 감사의 말씀을 전해 드립니다. 많은 분들의 가르침과 지도로 연구를 잘 마무리 할 수 있었습니다. 학교에서 배운 많은 가르침들 가지고 끊임 없이 배우고 성장하는 엔지니어가 되도록 하겠습니다.

감사합니다.